

Predição e Inteligência Analítica para Alfabetização no Brasil

Uma solução reproduzível de Machine Learning para estimar risco e priorizar apoio territorial

CURSO	Pós-graduação em Inteligência Artificial
INTEGRANTE	Viviane Demarchi
GRUPO	143
DATA	9 de setembro de 2026
VERSÃO	2.0 - resultados reais consolidados

NOTA DE INTEGRIDADE | Todas as métricas preditivas foram calculadas sobre a exportação real de 160.978 registros. Resultados sintéticos não foram usados.

Fontes: Inep, Base dos Dados e IBGE | Pipeline Python e BigQuery SQL

Resumo executivo

O objetivo deste trabalho é antecipar o risco de não alfabetização de estudantes do 2º ano do Ensino Fundamental e transformar as probabilidades individuais em inteligência territorial para priorização de municípios. A solução reutiliza a arquitetura Bronze, Silver e Gold da Fase 2, incorpora contexto educacional defasado e atributos socioeconômicos do IBGE, compara modelos supervisionados e produz um ranking municipal interpretável.

A principal decisão metodológica foi excluir do modelo acionável a proficiência e qualquer indicador agregado do próprio resultado de 2024. Como a classificação oficial de alfabetização é definida pela proficiência, utilizar essa variável produziria um atalho circular, com aparência de excelente desempenho mas sem utilidade antes da avaliação. O modelo principal utiliza apenas informações de 2023, características territoriais estáveis e a meta de 2025.

Na amostra real, a regressão logística regularizada foi o melhor candidato. No teste formado apenas por municípios não vistos, obteve ROC-AUC de 0,661 e PR-AUC de 0,542, frente a uma prevalência de risco de 0,397. Isso equivale a ganho absoluto de 0,145 e relativo de 36,5% sobre a referência aleatória da curva Precisão-Recall. O resultado indica capacidade moderada de ordenação territorial, não precisão suficiente para decisões individuais automáticas.

A auditoria herdada da Fase 2 registra 3.867.999 linhas de estudantes, das quais 513.338 não estavam aptas à análise de desempenho. Restaram aproximadamente 3,35 milhões de registros aptos. A taxa nacional observada avançou de 55,9% em 2023 para 59,2% em 2024, aumento de 3,3 pontos percentuais, mas ficou 0,7 ponto abaixo da meta de 59,9%. Entre 5.232 comparações município-ano com meta, 2.788 (53,3%) atingiram ou superaram a referência e 2.444 (46,7%) ficaram abaixo. Esse quadro justifica uma ferramenta de triagem antecipada e territorial.

1. Contexto e problema de negócio

O Indicador Criança Alfabetizada considera alfabetizado o estudante que atinge o padrão de desempenho definido para a avaliação nacional. Na base utilizada, o corte corresponde a 743 pontos na escala do Saeb. Embora o indicador observado seja indispensável para monitoramento, ele chega depois da aplicação da avaliação. Para uma política pública ser preventiva, é necessário estimar risco antes que o resultado corrente seja conhecido.

Este trabalho responde a cinco perguntas:

- 1. Quais fatores disponíveis antes da avaliação estão mais associados ao risco de não alfabetização?
- 2. Quais municípios devem ser priorizados para diagnóstico e apoio?
- 3. Quais municípios possuem perfis contextuais semelhantes?
- 4. Qual é a distância entre a alfabetização prevista e a meta de 2025?
- 5. Como transformar o modelo em um instrumento de apoio, sem automatizar decisões sensíveis?

O produto analítico não substitui avaliação pedagógica, visita técnica ou decisão humana. Seu papel é ordenar prioridades sob restrição de recursos.

2. Dados, escopo e proveniência

2.1 Origem

A fonte principal é a Avaliação da Alfabetização do Inep, disponibilizada em formato tratado pela Base dos Dados. A Fase 2 integrou as tabelas no projeto GCP tech-alfabetizacao-vdemarchi, com as camadas:

- silver.alunos, contendo registros por estudante;
- gold.indicador_municipio, contendo metas, resultados e auditorias municipais;

- gold.indicador_uf, gold.indicador_brasil e gold.evolucao_alfabetizacao, utilizadas no contexto agregado;
- quality.resumo_validacao_final, com regras de qualidade.

O enriquecimento usa as tabelas públicas de população e PIB municipal do IBGE mantidas pela Base dos Dados. Todas as variáveis de contexto foram limitadas a 2023 para prever o desfecho de 2024.

2.2 Recorte analítico

- População-alvo: estudantes da rede municipal, 2º ano do Ensino Fundamental, presentes, com prova preenchida e registro apto.
- Unidade de modelagem: estudante.
- Unidade de decisão: município.
- Período do desfecho: 2024.
- Classe positiva: nao_alfabetizado = 1.
- Chave de separação: id_municipio.

A opção pela rede municipal mantém coerência com as metas e resultados de gold.indicador_municipio, que foram construídos para rede_codigo = 3 na Fase 2.

2.3 Proteção de dados


O identificador do aluno é utilizado dentro do BigQuery apenas para construir uma amostra determinística e não é exportado. O repositório ignora microdados, credenciais, modelos e previsões individuais. Apenas resultados agregados podem ser publicados.

3. Análise exploratória e qualidade

3.1 Volume e elegibilidade

A Silver contém 3.867.999 registros de estudantes em 2023 e 2024. A regra apto_analise_desempenho exclui 513.338 registros relacionados principalmente a ausência ou prova não preenchida. O conjunto potencialmente elegível tem 3.354.661 registros, ou 86,7% do total.


Base pronta para analise, com recorte explicito de elegibilidade



Essa exclusão não deve ser interpretada como erro de engenharia. Entretanto, pode produzir viés de seleção se a ausência estiver relacionada ao próprio risco de não alfabetização. Por isso, participação anterior entra como atributo e o relatório recomenda monitoramento separado dos não participantes.

3.2 Evolução nacional e metas

O resultado nacional aumentou de 55,9% para 59,2% entre 2023 e 2024. O avanço de 3,3 pontos percentuais não foi suficiente para alcançar a meta de 2024, de 59,9%. A trajetória registrada na fonte chega a 80% em 2030.



O ganho nacional pode coexistir com forte heterogeneidade. Nas 5.232 linhas município-ano com comparação válida, 46,7% permaneceram abaixo da meta. Portanto, a média nacional não é suficiente para orientar alocação territorial.


3.3 Consistência e ausências

A tabela Gold municipal possui 10.951 chaves distintas e nenhuma duplicidade. Foram executadas 59 regras de qualidade. A auditoria de relacionamento identificou, em 2023, 4.596 pares correspondentes com diferenças entre taxas provenientes das tabelas de meta e de resultado; em 2024, as 5.352 chaves correspondentes apresentaram taxas iguais. O modelo utiliza explicitamente taxa_alfabetizacao_resultado de 2023, mantendo uma única definição documentada.

Na exportação usada pelo modelo, as 160.978 linhas cobrem 5.350 municípios. Há 95.556 estudantes classificados como alfabetizados e 65.422 como não alfabetizados, correspondendo a 59,36% e 40,64%. A estimativa descritiva ponderada por peso_aluno é 58,85% de alfabetização; o modelo, voltado à classificação de cada registro observado, trata as linhas sem ponderação.

Os maiores percentuais de ausência foram 19,04% em total de avaliados de 2023, 2,57% em participação anterior, 1,36% em meta de 2025 e 0,48% nas duas medidas anteriores de desempenho. O pipeline preserva os nulos e realiza imputação da mediana dentro de cada ajuste, evitando que estatísticas do teste contaminem o treino. Foram encontradas 646 linhas analiticamente idênticas; elas foram mantidas porque o identificador do estudante não foi exportado e estudantes diferentes podem compartilhar todos os atributos municipais e o mesmo desfecho.

A primeira versão da consulta havia multiplicado o PIB per capita por mil, embora a tabela pública já fornecesse o PIB na unidade compatível com a divisão pela população. A mediana anômala, acima de R\$ 41 milhões por habitante, revelou o problema. O SQL foi corrigido e o pipeline aplicou, de forma registrada, a divisão por mil ao arquivo já exportado. Após a correção, a mediana ficou em aproximadamente R\$ 41,7 mil por habitante.




3.4 Hipóteses analíticas

- H1: municípios com menor taxa e menor média de Português em 2023 apresentam maior risco em 2024.
- H2: menor participação em 2023 está associada a maior incerteza e possível viés de seleção.
- H3: população e PIB per capita capturam diferenças de escala e capacidade socioeconômica, mas não representam renda individual.
- H4: persistem padrões regionais após controlar pelo histórico municipal.
- H5: um modelo não linear pode capturar interações, mas terá maior risco de sobreajuste que a regressão logística.

As hipóteses são preditivas. A confirmação de associação não constitui evidência causal.

A correlação de Spearman sustenta H1: risco de não alfabetização apresenta associação negativa de aproximadamente -0,255 com a média de Português anterior, -0,249 com a taxa de alfabetização anterior e -0,148 com a participação anterior. A taxa anterior, a média anterior e a meta de 2025 são fortemente correlacionadas entre si, o que exige cautela ao interpretar importância isolada.



4. Engenharia de atributos e vazamento

4.1 Atributos do modelo principal

Grupo	Atributos
Educacional	taxa de alfabetização anterior, média de Português anterior, participação anterior, estudantes avaliados no ano anterior
Territorial	código da UF e região
Socioeconômico	população anterior e PIB per capita anterior
Planejamento	meta de alfabetização de 2025

4.2 Variáveis proibidas

proficiencia, alfabetizado_codigo, alfabetizado_descricao, taxas de alfabetização de 2024, média de Português de 2024 e proporções dos níveis 0 a 8 são bloqueadas. A proficiência não é apenas correlacionada ao alvo: ela participa de sua definição. Identificadores de estudante, escola e município também não são preditores, evitando memorização e alta cardinalidade; o município é somente o grupo do split.

Um teste automatizado falha caso uma coluna proibida seja incluída no conjunto de atributos. Um experimento diagnóstico opcional mostra a diferença entre um modelo circular com proficiência e o modelo acionável, sem permitir que o primeiro seja selecionado.

Desenho preditivo sem vazamento do resultado de 2024



Proficiencia e agregacoes do proprio desfecho sao bloqueadas no modelo principal.

Fluxo metodológico

5. Pipeline de Machine Learning

5.1 Pré-processamento integrado

O ColumnTransformer contém:

- mediana para valores numéricos ausentes;
- moda para categorias ausentes;
- padronização dos atributos numéricos;
- one-hot encoding com tratamento de categorias desconhecidas;
- exclusão de todas as colunas não aprovadas.

O transformador e o estimador são serializados juntos. Isso garante que treinamento e inferência executem as mesmas regras.

5.2 Particionamento

Foi adotada a proporção aproximada 60/20/20 para treino, validação e teste. GroupShuffleSplit mantém todos os estudantes de um município na mesma partição. Essa decisão produz uma avaliação mais exigente: o teste mede capacidade de generalizar para municípios não vistos, e não apenas para novos alunos de localidades já memorizadas.

Com apenas 2023 e 2024, e usando 2023 como histórico, não existe um terceiro ano para teste temporal completo. Quando o desfecho de 2025 estiver disponível, recomenda-se treinar até 2024 e testar exclusivamente em 2025.

5.3 Modelos e otimização

Foram preparados cinco candidatos:

- 1. DummyClassifier como baseline de prevalência;
- 2. regressão logística com $C = 0,3$;
- 3. regressão logística com $C = 1,0$;
- 4. Random Forest com profundidade máxima 16 e folha mínima 10;
- 5. Random Forest sem limite explícito de profundidade e folha mínima 20.

A comparação de hiperparâmetros ocorre somente na validação. O modelo com maior PR-AUC, excluído o baseline, é reajustado em treino mais validação. Dois limiares são escolhidos exclusivamente na validação: o maior F2 para triagem de alta sensibilidade e a maior acurácia balanceada para um uso operacional mais seletivo. O teste é acessado uma única vez.

5.4 Métricas

- PR-AUC: qualidade do ranking da classe de risco e critério principal.
- ROC-AUC: discriminação global.
- Recall: proporção de estudantes em risco identificados.
- Precisão: proporção dos alertas que corresponde ao evento observado.
- F2: síntese com prioridade para recall.
- Balanced accuracy: desempenho equilibrado entre classes.
- Brier score: qualidade probabilística e calibração.

O gap_pr_auc entre treino e validação é monitorado como sinal de sobreajuste.

6. Resultados do modelo

6.1 Comparação na validação


Modelo	PR-AUC	ROC-AUC	Recall	Precisão	F2	Gap PR-AUC
Regressão logística, C=0,3	0,544	0,654	0,987	0,438	0,789	0,017
Regressão logística, C=1,0	0,544	0,654	0,987	0,438	0,789	0,017
Random Forest, profundidade 16	0,541	0,653	0,987	0,438	0,789	0,059
Random Forest, folha mínima 20	0,541	0,653	0,984	0,440	0,789	0,057
Baseline de prevalência	0,420	0,500	1,000	0,420	0,784	-0,016

A regressão logística com $C=0,3$ venceu por pequena margem de PR-AUC e apresentou gap treino-validação menor que as Random Forests. A proximidade entre os candidatos mostra que o limite principal está na informação disponível, composta quase integralmente por contexto municipal, e não na falta de complexidade algorítmica.

6.2 Avaliação final no teste

Ponto de operação	Limiar	Alertas	Acc.	Acc. bal.	Precisão	Recall	F2
Triagem de alta sensibilidade	0,230	88,8%	46,9%	55,1%	42,5%	95,0%	76,2%
Uso equilibrado recomendado	0,515	36,6%	62,8%	60,5%	53,5%	49,4%	50,1%

Em ambos os pontos, ROC-AUC = 0,661, PR-AUC = 0,542 e Brier = 0,225, pois essas métricas avaliam as probabilidades e não dependem do corte. No ponto equilibrado, 12.106 de 33.032 registros recebem alerta: são 6.479 verdadeiros positivos, 5.627 falsos positivos, 6.647 falsos negativos e 14.279 verdadeiros negativos. Na triagem ampla, o recall sobe para 95,0%, mas 29.336 registros seriam sinalizados. Por isso, a recomendação principal é utilizar o escore contínuo como ranking territorial; o limiar deve refletir a capacidade real de atendimento.




Curvas e matriz de confusão no teste territorial

6.3 Interpretação

A importância por permutação mede a queda de PR-AUC quando cada atributo é embaralhado no teste. Valores maiores indicam maior contribuição preditiva. A interpretação deve observar duas regras:

- 1. importância não prova causalidade;
- 2. atributos correlacionados podem dividir importância entre si.



O código da UF foi o atributo mais importante, com queda média de 0,033 na PR-AUC quando embaralhado. Em seguida aparecem média de Português de 2023, com 0,026, e taxa de alfabetização anterior, com 0,018. Participação anterior e região acrescentam informação menor. Valores próximos de zero ou negativos para meta, PIB per capita, população e quantidade avaliada significam ausência de

ganho incremental estável neste teste, e não efeito causal negativo.

Como verificação de vazamento, um modelo diagnóstico que recebeu somente proficiência alcançou ROC-AUC e PR-AUC iguais a 1,000. O resultado perfeito confirma que a variável contém a resposta e deve permanecer proibida no modelo acionável.


7. Inteligência municipal

7.1 Ranking de risco

As probabilidades do teste são agregadas por município. Para cada localidade, a solução entrega risco médio, taxa prevista de alfabetização, intervalo aproximado de 95%, número de estudantes e déficit para a meta de 2025. Como os atributos disponíveis são municipais, todos os estudantes da mesma localidade recebem o mesmo escore; portanto, o produto deve ser interpretado como triagem territorial, não diagnóstico individual.

O ranking bruto contém 1.070 municípios de teste. Para reduzir instabilidade, a lista principal exige ao menos 30 estudantes na amostra, critério atendido por 215 municípios. Os cinco primeiros são:

Município	UF	n no teste	Risco previsto	Risco observado	Déficit para meta
Senhor do Bonfim	BA	58	81,3%	77,6%	16,8 p.p.
Paulo Afonso	BA	99	80,6%	67,7%	20,8 p.p.
Pilão Arcado	BA	40	79,6%	77,5%	19,0 p.p.
Santa Cruz	RN	38	78,4%	55,3%	15,3 p.p.
Remanso	BA	36	77,9%	52,8%	18,4 p.p.



Esses nomes não formam uma sentença definitiva: indicam onde iniciar uma investigação. Diferenças entre risco previsto e observado, como em Santa Cruz e Remanso, reforçam que o modelo é moderado e que o contexto local deve prevalecer.

7.2 Municípios semelhantes

O módulo não supervisionado agrega atributos contextuais por município, padroniza as variáveis e testa de dois a cinco clusters. O número de grupos é escolhido pelo maior silhouette score. Como o alvo de 2024 não entra nessa etapa, os clusters descrevem contexto, não desempenho corrente. A solução escolheu três grupos, com silhouette de 0,339:

Cluster	Municípios	Síntese do perfil
0	2.900	desempenho e participação anteriores mais altos; municípios menores
1	2.443	desempenho anterior mais baixo e menor PIB per capita médio
2	7	grandes centros, com população média de 4,09 milhões e escala educacional muito maior

O uso sugerido é criar carteiras de intervenção: municípios de um mesmo perfil podem compartilhar diagnóstico e desenho de apoio, desde que análises locais confirmem a semelhança.

7.3 Previsão de metas futuras

A taxa prevista é calculada como $100 \times (1 - \text{risco_medio})$. O déficit é $\text{meta_2025} - \text{taxa_prevista}$. Valores positivos indicam necessidade estimada de avanço. Trata-se de previsão de cenário, não de garantia sobre o resultado futuro.

8. Respostas às perguntas de negócio

Pergunta	Resposta entregue pela solução
Fatores de maior impacto	UF, média de Português anterior, taxa de alfabetização anterior, participação e região lideraram a importância preditiva
Municípios em risco	Senhor do Bonfim, Paulo Afonso, Pilão Arcado, Santa Cruz e Remanso lideraram a lista com amostra mínima no teste
Regiões com padrões semelhantes	três clusters separam municípios de melhor histórico, histórico mais frágil e grandes centros
Municípios sem resultado futuro	risco médio foi convertido em taxa prevista e comparado à meta municipal de 2025
Influência das variáveis	importância por permutação no teste e diagnóstico de vazamento permitem distinguir sinal útil de resposta circular

9. Aplicação em políticas públicas

Propõe-se um ciclo mensal ou trimestral de uso:

- 1. atualizar contexto e histórico;
- 2. calcular risco e incerteza;
- 3. selecionar municípios prioritários por risco, déficit e cobertura;
- 4. realizar diagnóstico pedagógico local;
- 5. pactuar apoio, formação e materiais;
- 6. medir participação e resultado da edição seguinte;
- 7. recalibrar o modelo e auditar diferenças entre grupos.

O escore não deve decidir matrícula, promoção, sanção, transferência de recursos ou rotulação individual. Uma política responsável usa o modelo para oferecer apoio adicional, nunca para retirar direitos.

10. Limitações

- A base tem apenas dois anos úteis para o desenho proposto.
- Atributos socioeconômicos são municipais e podem ocultar desigualdade interna.
- A ausência de atributos individuais faz o escore variar entre municípios, não entre estudantes da mesma localidade.
- Estudantes ausentes ou sem prova preenchida não possuem desfecho observado.
- O split territorial é rigoroso, mas não substitui validação temporal.
- A amostra local reduz custo computacional, embora preserve a prevalência por hash.
- Apenas 215 municípios de teste possuem pelo menos 30 registros; rankings de localidades menores são mais instáveis.
- O intervalo apresentado é uma aproximação binomial e não incorpora toda a incerteza do modelo.
- `peso_aluno` foi usado em auditoria descritiva, mas não no ajuste desta versão.
- Mudanças de instrumento, política ou população podem causar drift.
- As associações não identificam efeito causal de uma intervenção.

11. Conclusão

O projeto entrega uma arquitetura preditiva reproduzível e alinhada ao uso público: dados defasados no tempo, proteção automatizada contra vazamento, comparação de modelos, dois limiares operacionais, teste territorial e interpretação agregada. A regressão logística obteve discriminação moderada e ganho relevante de PR-AUC sobre a prevalência, mas não sustenta automação individual. Sua contribuição prática é transformar diagnóstico retrospectivo em uma fila transparente de investigação municipal, acompanhada de tamanho amostral, incerteza, limitações e supervisão humana explícitas.

Referências

- BRASIL. Instituto Nacional de Estudos e Pesquisas Educacionais Anísio Teixeira. Avaliação da Alfabetização. Disponível em: <https://www.gov.br/inep/pt-br/areas-de-atuacao/avaliacao-e-exames-educacionais/avaliacao-da-alfabetizacao>.
- BASE DOS DADOS. Avaliação da Alfabetização. Disponível em: <https://basedosdados.org/dataset/073a39d4-89cf-4068-b1e8-34ed0d9c0b72>.
- BASE DOS DADOS. População Brasileira. Disponível em: <https://basedosdados.org/dataset/d30222ad-7a5c-4778-a1ec-f0785371d1ca>.
- BASE DOS DADOS. Produto Interno Bruto (PIB). Disponível em: <https://basedosdados.org/dataset/fcf025ca-8b19-4131-8e2d-5ddb12492347>.
- SCIKIT-LEARN DEVELOPERS. Scikit-learn User Guide. Disponível em: https://scikit-learn.org/stable/user_guide.html.